

ZG6: Analyse de scènes audio

Détection et Localisation d'une source sonore (AAV2 / AAV3)

V. Choqueuse

Ecole Nationale d'Ingénieurs de Brest

P2025

Introduction

Les Signaux Audio

- Un peu de psychoacoustique

- Caractéristiques des signaux

- Représentations des signaux

Détecteur d'activité (VAD)

- Approches par Critères Discriminants

- Approche Statistique

DOA: Direction of Arrival Estimation

- Approches Temporelles

- Approches Fréquentielles


Retours d'expérience

Discussions

Objectif

- Développer un système permettant de suivre une source sonore.

Méthodologie




- **Détecter** la présence d'un locuteur (*Voice Activity Detection*),
- **Estimer** la position du locuteur dans l'espace (*Direction of Arrival Estimation*),


Prototypage des algorithmes puis implémentation sur cible.

Matériels disponibles

- STM32F411
- X-NUCLEO-CCA02M2
- STEVAL-MIC003V1



(a) Utilisation des deux micros embarqués




(b) Utilisation des micros STEVAL-MIC003V

Figure: Choix des micros.

Matériels de test



(a) Enceintes



(b) Carte son Focusrite Scarlett


Figure: Matériels de test disponible (salle A014)

- Quelques précautions:
 - Vérifier les potentiomètres de volume avant chaque utilisation.
 - Attention à respecter les étudiants et enseignants dans les salles voisines.
 - **Atteignez le matériel après utilisation.**


Les Signaux Audio

Un peu de psychoacoustique

- Système : Deux capteurs fixes (nos deux oreilles) + une unité de traitement (notre cerveau),
- Bande fréquentielle audible: $[0, 20000\text{Hz}]$,
- Sensation d'intensité sonore non uniforme dans cette bande.



(a) Bande Fréquentielle Audible




(b) Courbes d'isophonie


Figure: Le système auditif humain

Un peu de psychoacoustique

- Localisation sonore
 - Position Azimutale: Analyse de la **Différence de temps Interaurale** (ITD),
 - Position 3D: Analyse de l'effet de filtrage du son (binaural),
 - Raffinement de la position: Rotation de la tête.



(a) Position Azimutale



(b) Position 3D

Figure: Localisation sonore chez les humains.

Caractéristiques des signaux

$$x_l[n] = x_l(t)|_{t=nT_s}$$

- Format CD Audio (Sony & Philips - 1982):
 - Fréquence d'échantillonnage: $F_s = \frac{1}{T_s} = 44100$ Hz ($F_s/2 < 20000$ Hz),
 - Quantification: 16 bits,
 - Nombre de canaux: 2 (gauche + droite).
- Modèle mathématique (vecteur de taille $N_{tot} \times 1$):

$$\mathbf{x}_l = \begin{bmatrix} x_l[0] \\ \vdots \\ x_l[N_{tot} - 1] \end{bmatrix} \quad \text{où } l = 1, 2$$

Représentations des signaux

- Représentation Temporelle

$$x_l[n], \forall n = 0, 1 \dots, N_{tot} - 1$$




Figure: Représentation temporelle du signal $x_1[n]$.

Représentations des signaux

- Représentation Fréquentielle

$$X_I[k] = \sum_{n=0}^{N_{tot}-1} x_I[n] e^{-\frac{2j\pi nk}{N_{tot}}}, \forall k = 0, 1, \dots, N_{tot} - 1$$




Figure: Représentation fréquentielle du signal $x_1[n]$.

Représentations des signaux

- Short Time Fourier Transform (STFT):

$$X_I[m, k] = \sum_{n=0}^{N-1} x_I[n] w[n - m] e^{-\frac{2j\pi nk}{N}}$$

- $w[n]$: fenêtre de pondération temporelle.




Figure: Représentation du module (en dB) de la STFT du signal $x_1[n]$.

Tests audio

Le Moodle de la ZG6 contient un fichier bin à téléverser sur la carte permettant d'utiliser la carte d'extension comme un périphérique d'entrée audio USB

- Documents ressources > signal_Fichier_bin_STM32.bin.

Projet Audio

- Prototypage Offline Python / C:
<https://git.enib.fr/choqueuse/zg6-signal-etudiants>
- Implémentation sur cible STM32:
<https://git.enib.fr/bouchare/zg6-elec-etudiants>
 - Dossier pdm

Probabilité que l'implémentation sur cible fonctionne sans prototypage: $P_{ok} = \epsilon$!

Fichier Source (pdm > src > main_pdm.c)

```
uint16_t pcm_buf[CHANNEL_NB*SAMPLING_FREQ/1000*N_MS_PER_INTERRUPT]

...

int main(void)
{
    /Audio initialisation
    ...
    while (1) {
        if (flag) {
            AUDIO_IN_PDMPToPCM(pdm_buf , pcm_buf);
            flag=0;
            /* Do something with PCM data */
        }
    }
    return 0;
}
```

Gestion de l'audio

- Structure des buffers audios:

x_0[0]	x_1[0]	x_0[1]	x_1[1]	x_0[2]	x_1[2]	x_0[3]	...
--------	--------	--------	--------	--------	--------	--------	-----

Structure du buffer pcm_buf (échantillons entrelacés gauche/droite)

- Spécificités :
 - Type échantillons: `uint16_t` ($\rightarrow$ à convertir en signé)
 - Nombre d'échantillons: $N = \text{CHANNEL_NB} * \text{SAMPLING_FREQ} / 1000 * N_MS_PER_INTERRUPT$
 - Exemple: Audio Stéréo à 16kHz avec $N_MS_PER_INTERRUPT=10$, $N = 320$ échantillons.
 - Remarque: Attention à bien prendre des buffers suffisamment longs mais pas trop ($N_MS_PER_INTERRUPT \approx 10$)

Détecteur d'activité (VAD)

Détecteur à seuil

- Choix de l'hypothèse $\mathcal{H}_1$ si $\mathcal{T}(\mathbf{x}) > \tau$
 - $\mathcal{T}(\cdot)$: critère de détection,
 - τ : seuil de détection.

Critères de Performance

- Probabilité de détection élevée : $P_d \triangleq P[\mathcal{T}(\mathbf{x}) > \tau | \mathcal{H}_1]$.
- Probabilité de fausse alarme faible : $P_{fa} \triangleq P[\mathcal{T}(\mathbf{x}) > \tau | \mathcal{H}_0]$.

Détecteur d'activité (VAD)

Calibration du seuil de détection

- Le seuil de détection τ peut être déterminé à partir de la probabilité de fausse alarme $P_{fa} = P[\mathcal{T}(\mathbf{x}) > \tau | \mathcal{H}_0]$.




Figure: Calibration du seuil de détection τ (en rouge). La probabilité de fausse alarme P_{fa} correspond à l'aire en orange située à droite du seuil de détection.

Etat de l'art

- Approches basées sur des critères discriminants,
- Approches statistiques,
- (*Approche basées sur du Machine Learning*).

Principe

L'énergie du signal audio est "généralement" plus importante en présence d'un signal de parole (hypothèse $\mathcal{H}_1$).

Algorithme [1]


- Paramètre discriminant: Short Time Energy ($N \ll N_{tot}$)

$$\mathcal{T}_{STE}(\mathbf{x}) = \sum_{n=0}^{N-1} x^2[n] \quad (1)$$


- Détecteur à seuil: On choisit l'hypothèse $\mathcal{H}_1$ si

$$\mathcal{T}_{STE}(\mathbf{x}) > \tau$$


Exemple



(a) Représentation Temporelle



(b) Affichage du critère



(c) Sortie du détecteur

Figure: Illustration du détecteur Short Time Energy.

Motivations

Considérons l'énergie instantanée $x^2[n]$. Le critère $y[n] = \mathcal{T}_{STE}(\mathbf{x})$ peut être déterminé en filtrant l'énergie instantanée avec un filtre FIR de réponse impulsionnelle :

$$h[n] = \begin{cases} 1 & \text{si } 0 \leq n < N \\ 0 & \text{ailleurs} \end{cases}$$

Filtrage IIR

Il est possible d'utiliser une version IIR du filtre précédent en filtrant passe-bas l'énergie instantanée

$$y[n] = (1 - \alpha)y[n - 1] + \alpha x^2[n]$$

- Le coefficient $0 < \alpha < 1$ permet d'ajuster la fréquence de coupure du filtre.

VAD: Zero Crossings Rate

Principe

Le nombre de passage par zéro est plus élevé dans le cas d'un signal composé uniquement de bruit ($\mathcal{H}_0$).

Algorithme [1]

- Paramètre discriminant: Zero Crossings Rate (ZCR)


$$\mathcal{T}_{ZCR}(\mathbf{x}) = \frac{1}{N-1} \sum_{n=1}^{N-1} \mathbb{1}_{<0}(x[n]x[n-1]) \quad (2)$$

où $\mathbb{1}_{<0}(z)$ désigne la fonction indicatrice définie par


$$\mathbb{1}_{<0}(z) = \begin{cases} 1 & \text{si } z < 0 \\ 0 & \text{sinon} \end{cases}$$

- Détecteur à seuil: On choisit l'hypothèse $\mathcal{H}_1$ si $\mathcal{T}_{ZCR}^{-1}(\mathbf{x}) > \tau$.


Exemple



(a) Représentation Temporelle



(b) Affichage du critère



(c) Sortie du détecteur

Figure: Illustration du détecteur Zero Crossings Rate.

Principe

Les signaux de parole présentent des composantes fréquentielles généralement plus prononcées ($\mathcal{H}_1$).

Algorithme [2]

- Paramètre discriminant: *Long Term Spectral Divergence*

$$\mathcal{T}_{LTSD}(\mathbf{x}[n]) = \frac{1}{N} \sum_{k=0}^{N-1} \frac{|Y[n, k]|^2}{\sigma^2[k]} \quad (3)$$

- $\sigma^2[k]$: variance du bruit au *bin* k ,
- $|Y[n, k]|$: *long-term spectral envelope* au *bin* k

$$|Y[n, k]|^2 = \arg \max_{m \in [-M, M]} |X[n + m, k]|^2$$


Modèles statistiques

- Sous l'hypothèse $\mathcal{H}_0$, $X[k] \sim \mathcal{N}_c(0, \sigma^2[k])$,
- Sous l'hypothèse $\mathcal{H}_1$ $X[k] \sim \mathcal{N}_c(0, \sigma_s^2[k] + \sigma^2[k])$.


$$p(X[k]|\mathcal{H}_0) = \frac{1}{\pi\sigma^2[k]} e^{-\frac{|X[k]|^2}{\sigma^2[k]}}$$

$$p(X[k]|\mathcal{H}_1) = \frac{1}{\pi(\sigma_s^2[k] + \sigma^2[k])} e^{-\frac{|X[k]|^2}{\sigma_s^2[k] + \sigma^2[k]}}$$


Illustration



(a) Histogramme de $\Re(X[10])$.



(b) Histogramme de $\Im(X[10])$.



(c) Variance $\sigma^2[k]$.

Figure: Apprentissage des statistiques $\sigma^2[k]$ sur un signal réel composé uniquement d'un bruit seul (hypothèse $\mathcal{H}_0$).

Rapport de Vraisemblance pour le bin k

$$\mathcal{L}(X[k]) = \frac{p(X[k]|\mathcal{H}_1)}{p(X[k]|\mathcal{H}_0)} = \frac{1}{1 + \epsilon_k} e^{\frac{\gamma_k \epsilon_k}{1 + \epsilon_k}}$$

- SNR *apriori*: $\epsilon_k = \sigma_s^2[k]/\sigma^2[k]$,
- SNR *aposteriori*: $\gamma_k = |X[k]|^2/\sigma^2[k]$.


Algorithme [3]

- Rapport de Vraisemblance Généralisé:


$$\mathcal{T}_{GLRT}(\mathbf{x}) = \frac{1}{N} \sum_{k=0}^{N-1} (\gamma_k - \log(\gamma_k) - 1) \quad (4)$$

- SNR *aposteriori* : $\gamma_k = |X[k]|^2/\sigma^2[k]$.
- Détecteur à seuil: On choisit l'hypothèse $\mathcal{H}_1$ si $\mathcal{T}_{GLRT}(\mathbf{x}) > \tau$.


Exemple



(a) Représentation Temporelle



(b) Affichage du critère



(c) Sortie du détecteur

Figure: Illustration du détecteur Statistique

DOA: Direction of Arrival Estimation

Problématique

- Estimation de la position azimutale d'une source sonore à partir de plusieurs signaux sonores.




Figure: Estimation de l'angle d'arrivée en champ lointain

DOA: Direction of Arrival Estimation

Modèle de signal

Les signaux reçus par les deux capteurs peuvent s'exprimer sous la forme

$$x_1[n] = s[n] + b_1[n]$$

$$x_2[n] = s[n - \Delta] + b_2[n]$$

- $s[n]$ désigne le signal produit par la source sonore,
- $b_1[n]$ et $b_2[n]$ correspondent au bruit additif.
- $\Delta = \frac{\tau}{T_s} = \tau F_s$ correspond au nombre d'échantillons de retard.

Objectifs

1. **Estimation du décalage Δ** à partir de $\mathbf{x}_1$ et $\mathbf{x}_2$,
2. Calcul de τ à partir de Δ ,
3. Calcul de θ à partir de τ , c et D .

Exemple (source à Gauche)




Figure: Représentation temporelle du signal $x_1[n]$.




Figure: Représentation temporelle du signal $x_2[n]$.

Correlation Croisée [4]

$$\hat{\Delta}_{cc} = \arg \max_m R_{cc}[m]$$

$$\text{où } R_{cc}[m] \triangleq \frac{1}{N} \sum_{n=0}^{N-1} x_1[n]x_2[n+m]$$


Average Magnitude Difference Function (AMDF) [4]

$$\hat{\Delta}_{amd} = \arg \min_m R_{amd}[m]$$


$$\text{où } R_{amd}[m] \triangleq \frac{1}{N} \sum_{n=0}^{N-1} |x_1[n] - x_2[n+m]|$$

Exemple

- Localisation d'une source située à gauche, au centre et à droite.



(a) Estimateur CC.



(b) Estimateur AMDF.

Figure: Illustration des estimateurs CC et AMDF.

Remarques

- Interpolation. En pratique, la valeur de Δ n'est pas entière. Dans ce contexte, il est nécessaire d'interpoler $R_{cc}[m]$ (ou $R_{amd}[m]$) au voisinage du maximum.
 - Voir [4] (interpolation parabolique).

Expression des Spectres

$$X_1[k] = S[k] + B_1[k]$$

$$X_2[k] = S[k]e^{-2j\pi k\Delta/N} + B_2[k]$$

GCC: Corrélation Croisée Généralisée [5]

$$\hat{\Delta}_{gcc} = \arg \max_m R_{gcc}[m]$$

$$\text{où } R_{gcc}[m] \triangleq \frac{1}{N} \sum_{k=0}^{N-1} W[k] G_{1,2}[k] e^{2j\pi km/N}$$

- $G_{1,2}[k] \triangleq X_1[k]X_2^*[k]$: Spectre croisé,
- $W[k]$: Fenêtre de pondération,
- $R_{gcc}[m]$: TFD inverse du spectre croisé pondéré.

GCC: Choix de la fenêtre de pondération

- Correlation Croisée simple:

$$W[k] = 1$$

- **GCC-PHAT** [6]:

$$W[k] = \frac{1}{|G_{1,2}[k]|}$$

Exemple

- Localisation d'une source située à gauche, au centre et à droite.




Figure: Illustration de l'algorithme GCC-Phat.

Phase du spectre croisé [5]

- Définition:

$$\varphi[k] \triangleq \text{Arg}[G_{1,2}[k]]$$


- Expression:

$$\varphi[k] = \Delta\omega_k + \epsilon[k]$$


- $\omega_k = \frac{2\pi k}{N}$,
- $\epsilon[k]$: influence de la contribution du bruit.

Exemple

- Localisation d'une source située à droite.



(a) Module $|G_{1,2}[k]|$



(b) Argument $\varphi[k] = \arg[G_{1,2}[k]]$

Figure: Representation du spectre croisé $G_{1,2}[k]$.

Rang	1	2	3	4	5	6
ω_k	0.0464	0.0423	0.0423	0.0423	0.0451	0.0462
$ G_{1,2}[k] $	1.309e+14	1.274e+14	1.232e+14	1.223e+14	1.067e+14	1.043e+14
$\varphi[k]$	0.0467	0.0643	0.0664	0.0646	0.0702	0.0573
$\varphi[k]/\omega_k$	1.005	1.520	1.570	1.524	1.556	1.240

Table: Ratio $\varphi[k]/\omega_k$ pour les 6 composantes les plus importantes


Phase du spectre croisé [5]

- Estimation de Δ par régression linéaire pondérée


$$\hat{\Delta}_{reg} = \arg \min_m \sum_{k=1}^{N-1} w[k] |\varphi[k] - m\omega_k|^2 \quad (5)$$

- $w[k]$: terme de pondération permettant d'accorder plus d'importance aux phases associées à des modules du spectre élevés.


Exemple



(a) Source située à gauche
($\hat{\Delta}_{reg} = -1.070$)



(b) Source située au centre
($\hat{\Delta}_{reg} = 0.196$)




(c) Source située à droite
($\hat{\Delta}_{reg} = 1.314$)


Figure: Illustration de l'approche par interpolation linéaire de la phase du spectre croisé. Utilisation des 50 composantes les plus importantes.

Séparation des micros

- Etudiant X: Mr, les algorithmes ne fonctionnent pas pour les signaux expérimentaux.
- Enseignant Y: OK, montrez-moi votre système d'acquisition sonore.
- Etudiant X: Oui, voilà.
- Enseignant Y: ...PLS



(a) Bien




(b) Pas bien

Figure: Utilisation d'un micro déporté (@copyright: promo 2022)

Retours d'expérience

Matériel Audio

- Etudiant Y: Ca n'est pas sérieux. Le matériel audio ne fonctionne pas.
- Enseignant X :
[père Noël est une ordure] C'est cela, oui [/père Noël est une ordure]



th-mann

Focusrite Scarlett 18i20 3rd Gen

★★★★★

Recevoir

Voir les variations de ce produit

459 €

Tout les prix (incl. TVA)

Disponibilité immédiate

Livraison gratuite estimée entre le Mercredi, 27.05. et le jeudi, 28.05.


1 C

AJOUTER AU PANIER

Savegarder Comparer Partager

97

CLASSIFICATION DES VENTES



th-mann

KRK RP5 RoKiT Classic

★★★★★

139 €

Tout les prix (incl. TVA)

Disponibilité immédiate

Livraison gratuite estimée entre le Mercredi, 27.05. et le jeudi, 28.05.

AJOUTER AU PANIER

Savegarder Comparer Partager

155

CLASSIFICATION DES VENTES

Basé sur les données de PRODUITS ACTUELS


Conseil

Prototypage

- Enseignant X:
 - Construisez une base de signaux propres et prototypez en offline vos algorithmes en utilisant directement des fonctions C.
 - Testez les sorties de vos fonctions C en python en utilisant votre base de signaux.
- Etudiant Y: C'est une perte de temps, autant coder directement sur la carte STM32.
- Enseignant X : OK, fais comme tu le sens.
- *(derniers jours du projet)*
- Enseignant X : Alors ca marche ?
- Etudiant Y: non.

Algorithme DOA

- Enseignant X: Avez vous vérifié que votre corrélation croisée marche bien ?
- Etudiant Y: Oui, ça marche très bien en offline.
- Enseignant X: Pourrais-je voir l'allure de votre corrélation croisée ?
- Etudiant Y: Oui, bien sur. Comme vous pouvez le constater, nous observons bien ici un pic pour un décalage de $\Delta m = 200$ échantillons ($F_s = 16\text{kHz}$).



- Enseignant X:

$$\Delta m = 200 \Rightarrow \Delta t = \frac{\Delta m}{F_s} = 0.0125s$$

$$\max(\Delta t) = 0.0125s \Rightarrow D = c \times \max(\Delta t) = 4.25m$$

- Enseignant X: Vous êtes en train de me dire que l'espacement entre vos deux micros est supérieur à 4.25 m ?
- Etudiant Y: ...PLS

Algorithme VAD

- Enseignant X: La Short Time Energy (STE) est donnée par :

$$\mathcal{T}_{STE}(\mathbf{x}) = \sum_{n=0}^{N-1} x^2[n]$$

- (quelques jours plus tard)*
- Etudiant Y : Le détecteur VAD basé sur le critère STE ne fonctionne pas !
- Enseignant X: Vous avez combien d'échantillons (valeur de N) pour calculer le critère STE.
- Etudiant Y : Nous avons fixé $N = 1$ échantillon.
- Enseignant X: ...PLS

Algorithme DOA

- Enseignant X: La corrélation croisée est donnée par :

$$R_{cc}[m] \triangleq \frac{1}{N} \sum_{n=0}^{N-1} x_1[n] x_2[n+m]$$

- *(quelques jours plus tard)*
- Etudiant Y : Il faut donner plus d'indication pour l'implémentation de la corrélation croisée en C. J'y ai passé 4 jours sans réussir car nous n'avions pas d'indication sur ce qu'il fallait changer par rapport à son implémentation en Python !
- ~~Enseignant X~~ : ...

Planning: AAv2 [semaine 1/évaluation semaine 2]

- Détecter correctement une activité sonore (VAD) via les micros audios embarqués sur la carte.
 - Correctement =
 - VAD relativement robuste: détection en environnement faiblement bruité (bruit de fond de niveau faible),
 - Résultat indépendant du positionnement de la source sonore.
 - Détecteur relativement rapide

Planning: AAv3 [semaine 1/évaluation semaine 2]

- Constituer correctement une base de données audios contenant des signaux enregistrés via les deux micros audio embarqués de la carte.
 - Correctement =
 - Le dispositif d'acquisition sonore possède un support de fixation adapté
 - La base de données est complète (scenario VAD et DOA) et facilement exploitable.

Planning: AAv2 [semaine 2 / évaluation semaine 3]

- Estimer correctement la provenant azimutale (DOA) des signaux sonores enregistrés via les deux micros audios embarqués de la carte.
 - Correctement =
 - DOA capable de localiser la source à ± 90 degrés.
 - Estimation de la position relativement robuste (environnement faiblement bruité).

Quelques Conseils

- Attention à bien séparer vos micros et à les placer sur un support adapté,
- Prototypiez d'abord vos algorithmes en offline avec une base de données organisée de signaux audios propres,
- N'espérez pas obtenir de bons résultats (VAD et DOA) sur des buffers de 10 échantillons,
- Privilégiez les algos les plus simples,
- Ne perdez pas trop de temps à développer vos algorithmes en Python, l'implémentation finale restera en C.



S Gökhan Tanyer and Hamza Ozer.

Voice activity detection in nonstationary noise.

IEEE Transactions on speech and audio processing,
8(4):478–482, 2000.



Javier Ramirez, José C Segura, Carmen Benitez, Angel
De La Torre, and Antonio Rubio.

Efficient voice activity detection algorithms using long-term
speech information.

Speech communication, 42(3-4):271–287, 2004.



Jongseo Sohn, Nam Soo Kim, and Wonyong Sung.

A statistical model-based voice activity detection.

IEEE signal processing letters, 6(1):1–3, 1999.

-  Giovanni Jacovitti and Gaetano Scarano.
Discrete time techniques for time delay estimation.
IEEE Transactions on signal processing, 41(2):525–533, 1993.
-  Michael S Brandstein and Harvey F Silverman.
A practical methodology for speech source localization with
microphone arrays.
Computer Speech & Language, 11(2):91–126, 1997.
-  Charles Knapp and Glifford Carter.
The generalized correlation method for estimation of time
delay.
IEEE transactions on acoustics, speech, and signal processing,
24(4):320–327, 1976.